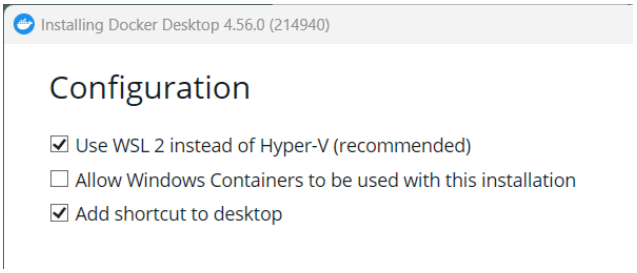
# TP 1




**Installation de l'environnement Hadoop sous Docker**

1. Sous Windows, ouvrez une fenêtre PowerShell et installez **wsl** : wsl --install .
2. Téléchargez **Docker Desktop** https://docs.docker.com/get-started/introduction/get-docker-desktop/ et l'installez avec les options suivantes :




3. Lancez Docker Desktop.

Pour la suite, vous pouvez utiliser un terminal PowerShell lancé à partir du menu Windows ou bien sous Docker Desktop, en bas à droite de la fenêtre.

4. Téléchargez et dézippez le fichier Docker-Hadoop.zip.
   Cette image est issue de https://github.com/big-data-europe/docker-hadoop
5. Placez-vous dans le répertoire Docker-Hadoop.
6. Lancez votre conteneur en arrière-plan : docker-compose up -d .

La commande docker-compose down permet de stopper le conteneur si besoin (CLI de Docker).

7. Sous PowerShell, lancez la commande : docker exec -it namenode bash, afin de vous placer dans le bash (interpréteur de commande shell) du nœud maître, le namenode.
8. Vérifiez qu'Hadoop est bien installé : hadoop version qui doit vous retourner le numéro de version d'Hadoop.
9. Quittez le bash : exit afin de revenir sous PowerShell dans le répertoire Docker-Hadoop.

10. Installez Spark sous Hadoop en copiant le répertoire spark-3.1.2-bin-hadoop3.2 sous le namenode : docker cp .\spark-3.1.2-bin-hadoop3.2\ namenode:/opt/spark-3.1.2 .
11. Revenez dans le bash du namenode : docker exec -it namenode bash .
12. Lancez la commande : ./opt/spark-3.1.2/bin/spark-shell afin de vérifier l'installation de Spark. Vous devez voir le numéro de version de Spark et vous retrouvez dans un terminal scala> . CTRL + C pour en sortir et revenir sous le namenode.

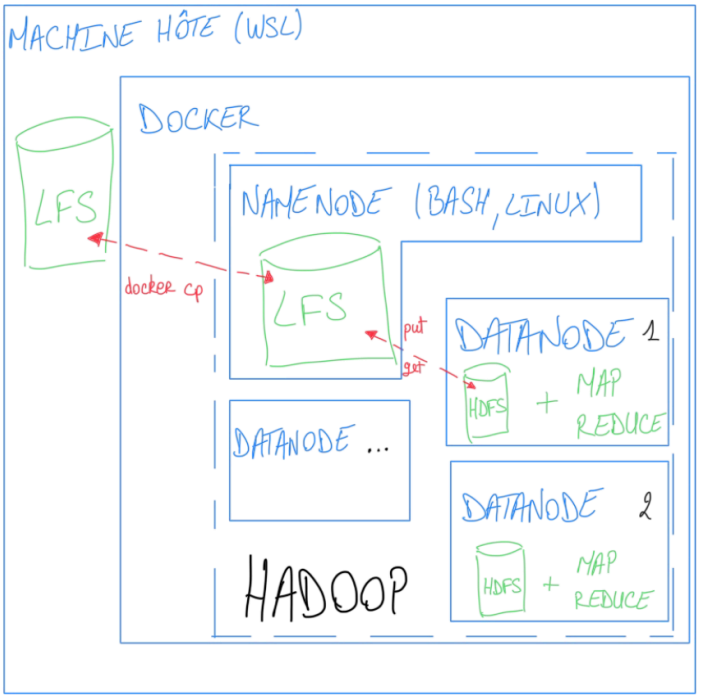
**Manipulations du** Hadoop File System Shell

Toutes les commandes shell pour HDFS ont le format : *hadoop fs -<commande> [option]*
Pour obtenir la liste des commandes : *hadoop fs*
Aide sur une commande : *hadoop fs -help <commande>*

Avant de poursuivre, vérifiez que vous êtes bien sous le bash du namenode.

1. Commencez par créer le répertoire de l'utilisateur root sous HDFS : hadoop fs -mkdir -p /user/root .
2. Récupérez le fichier "weblog_entries.txt".
3. Listez le contenu du répertoire par défaut du bash.
4. Listez le contenu du répertoire par défaut de l'utilisateur root sous HDFS.
5. Créez un répertoire "data" sous HDFS qui contient un répertoire "weblogs".
6. Copiez le fichier "weblog_entries.txt" dans le répertoire "weblogs". Pour cela, vous devez tout d'abord copier ce fichier de votre machine vers le namenode sous Docker.
7. Listez le contenu du répertoire "weblogs".
8. Sous HDFS, copiez le fichier "weblog_entries.txt" dans le répertoire "data/web" sous le nom "log.txt" et affichez sur la sortie standard les dernières lignes du fichier "log.txt".
9. Effacez le répertoire "weblogs".
10. Copiez le fichier "log.txt" dans le bash du namenode.
11. La plupart de ces actions peuvent être réalisées sur http://localhost:9870 dans le menu Utilities / Browse the file system.

**Architecture Hadoop sous Docker**




- - - © Ponyori - - -